Tutoria_88.11_PUCPR - DataSet STJ - [Decisões]

November 15, 2025

#Dataset Dados Abertos STJ - Íntegras de Decisões Terminativas e Acórdãos do Diário da Justiça (Decisões)

##Experimento 08: Realizando curva de convergência durante treinamento do modelo.

##Importação de bibliotecas e declaração de variáveis globais

[1]:
```
import torch

# Check if a GPU (CUDA) is available
if torch.cuda.is_available():
    print("GPU is available!")
    print("Device Name:", torch.cuda.get_device_name(0))
else:
    print("GPU not available, using CPU.")

# This is the line you'd use in your script to send your model or data to the␣
 ↪device
device = torch.device("cuda" if torch.cuda.is_available() else "cpu")
print(f"Using device: {device}")
```

```
GPU is available!
Device Name: Tesla V100S-PCIE-32GB
Using device: cuda
```

[2]:
```
import pandas as pd

# Define the base path to the dataset folder
base_path = 'dataset/'
install_evaluate = False

EPOCHS = 150
APPROACH_EXECUTION = 'epoch' # 'step'
```

###Carregar classe/rótulo para a decisão (Favorável ou Não ao Réu)

[3]:
```
# Define file paths
file_path = base_path + 'descricao-decisao-julgamento.csv'
```

```
# Load each CSV file into a dataframe
try:
    dfTipoDecisao = pd.read_csv(file_path, sep=';')
    print(f"Successfully loaded {file_path} into dataframe 'dfTipoDecisao'")
    display(dfTipoDecisao.head())
except FileNotFoundError:
    print(f"Error: File not found at {file_path}")
except Exception as e:
    print(f"An error occurred while loading {file_path}: {e}")
```

```
Successfully loaded dataset/descricao-decisao-julgamento.csv into dataframe
'dfTipoDecisao'
```

	COD_TEOR_DECISAO	DESC_TEOR_DECISAO	DESC_RSULT_JGTO	RESULTADO_RESUMIDO	DECISAO_FAVORAVEL
0	1	Concedendo	AGRAVO CONHECIDO EM PARTE E, NESSA PARTE, PROVIDO	PARCIALMENTE CONHECIDO E PROVIDO	S
1	1	Concedendo	Agravo regimental provido	PROVIDO	S
2	1	Concedendo	CONCEDENDO HABEAS CORPUS	CONCEDIDO	S
3	1	Concedendo	CONCEDENDO HABEAS DATA	CONCEDIDO	S
4	1	Concedendo	CONCEDENDO MANDADO DE SEGURANÇA	CONCEDIDA	S

##Carregar metadados das decisões (Documento, Processo, Nro de Registro, Ministro, Teor).

[4]:
```
file_path = base_path + 'metadados-decisoes-acordaos-dj052025.csv'

try:
    dfMetaDadosDecisao = pd.read_csv(file_path, sep=';')
    print(f"Successfully loaded {file_path} into dataframe␣
 ↪'dfMetaDadosDecisao'")
    display(dfMetaDadosDecisao.head(3))
except FileNotFoundError:
    print(f"Error: File not found at {file_path}")
except Exception as e:
    print(f"An error occurred while loading {file_path}: {e}")
```

```
Successfully loaded dataset/metadados-decisoes-acordaos-dj052025.csv into
```

dataframe 'dfMetaDadosDecisao'

```
   SEQDOCUMENTO DATAPUBLICACAO TIPODOCUMENTO  NUMEROREGISTRO       PROCESSO  \
0     309631639     2025-05-05       DECISÃO    202000946481        TP 2695
1     310378377     2025-05-05       DECISÃO    202400362531  AREsp 2562174
2     309409286     2025-05-05       DECISÃO    202401080738   REsp 2132967

  DATARECEBIMENTO DATADISTRIBUICAO             NM_MINISTRO RECURSO  \
0      2020-04-25       2020-04-27   MARIA ISABEL GALLOTTI     NaN
1      2024-02-09       2024-02-28  JOÃO OTÁVIO DE NORONHA     NaN
2      2024-04-02       2024-04-04      MESSOD AZULAY NETO     NaN

         TEOR                                DESCRICAOMONOCRATICA  \
0     Negando  Prejudicada a ação de #{nome_da_parte} #{campo…
1     Negando  Conhecido o recurso de #{nome_da_parte} e não-…
2  Concedendo  Conhecido o recurso de #{nome_da_parte} e prov…

                  ASSUNTOS
0                     4993
1  11806, 7752, 7780, 7779
2              3416, 3435
```

##Carregar detalhes das decisões

[5]:
```python
# Define file paths
file_path = base_path + 'decisoes-acordaos-dj052025.csv'

try:
    dfDetalheDecisao = pd.read_csv(file_path, sep=';')
    print(f"Successfully loaded {file_path} into dataframe 'dfDetalheDecisoes'")
    display(dfDetalheDecisao.head(3))
except FileNotFoundError:
    print(f"Error: File not found at {file_path}")
except Exception as e:
    print(f"An error occurred while loading {file_path}: {e}")
```

```
Successfully loaded dataset/decisoes-acordaos-dj052025.csv into dataframe
'dfDetalheDecisoes'

   SEQDOCUMENTO  ACORDAO EMENTA  RELATORIO  VOTO  \
0     309631639      NaN    NaN        NaN   NaN
1     310378377      NaN    NaN        NaN   NaN
2     309409286      NaN    NaN        NaN   NaN

                                             DECISAO
0  O presente pedido de contracautela tinha por o…
1  Trata-se de agravo em recurso especial interpo…
2  Trata-se de recurso especial interposto por MA…
```

[6]:
```
dfMetaDadosDecisao.shape
```

[6]:
```
(48588, 12)
```

[7]:
```
dfDetalheDecisao.shape
```

[7]:
```
(48027, 6)
```

##Tratamento dos dados ###Exclusão de campos desnecessários

[8]:
```
dfMetaDadosDecisao.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 48588 entries, 0 to 48587
Data columns (total 12 columns):
 #   Column                Non-Null Count  Dtype
---  ------                --------------  -----
 0   SEQDOCUMENTO          48588 non-null  int64
 1   DATAPUBLICACAO        48588 non-null  object
 2   TIPODOCUMENTO         48588 non-null  object
 3   NUMEROREGISTRO        48588 non-null  int64
 4   PROCESSO              48588 non-null  object
 5   DATARECEBIMENTO       48588 non-null  object
 6   DATADISTRIBUICAO      48588 non-null  object
 7   NM_MINISTRO           48588 non-null  object
 8   RECURSO               6200 non-null   object
 9   TEOR                  48588 non-null  object
 10  DESCRICAOMONOCRATICA  48588 non-null  object
 11  ASSUNTOS              48588 non-null  object
dtypes: int64(2), object(10)
memory usage: 4.4+ MB
```

[9]:
```
dfMetaDadosDecisao.head(3)
```

[9]:

	SEQDOCUMENTO	DATAPUBLICACAO	TIPODOCUMENTO	NUMEROREGISTRO	PROCESSO
0	309631639	2025-05-05	DECISÃO	202000946481	TP 2695
1	310378377	2025-05-05	DECISÃO	202400362531	AREsp 2562174
2	309409286	2025-05-05	DECISÃO	202401080738	REsp 2132967

	DATARECEBIMENTO	DATADISTRIBUICAO	NM_MINISTRO	RECURSO
0	2020-04-25	2020-04-27	MARIA ISABEL GALLOTTI	NaN
1	2024-02-09	2024-02-28	JOÃO OTÁVIO DE NORONHA	NaN
2	2024-04-02	2024-04-04	MESSOD AZULAY NETO	NaN

	TEOR	DESCRICAOMONOCRATICA
0	Negando	Prejudicada a ação de #{nome_da_parte} #{campo…
1	Negando	Conhecido o recurso de #{nome_da_parte} e não-…
2	Concedendo	Conhecido o recurso de #{nome_da_parte} e prov…

```
                  ASSUNTOS
0                     4993
1  11806, 7752, 7780, 7779
2               3416, 3435
```

[10]:
```
dfMetaDadosDecisao.
 ↪drop(columns=['DATAPUBLICACAO','TIPODOCUMENTO','DATARECEBIMENTO','DATADISTRIBUICAO','ASSUNT
 ↪inplace=True)
dfMetaDadosDecisao.head(3)
```

[10]:
```
   SEQDOCUMENTO  NUMEROREGISTRO       PROCESSO             NM_MINISTRO  \
0     309631639    202000946481        TP 2695   MARIA ISABEL GALLOTTI
1     310378377    202400362531  AREsp 2562174  JOÃO OTÁVIO DE NORONHA
2     309409286    202401080738   REsp 2132967      MESSOD AZULAY NETO

  RECURSO        TEOR                                DESCRICAOMONOCRATICA
0     NaN     Negando  Prejudicada a ação de #{nome_da_parte} #{campo…
1     NaN     Negando  Conhecido o recurso de #{nome_da_parte} e não-…
2     NaN  Concedendo  Conhecido o recurso de #{nome_da_parte} e prov…
```

[11]:
```
dfDetalheDecisao.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 48027 entries, 0 to 48026
Data columns (total 6 columns):
 #   Column        Non-Null Count  Dtype
---  ------        --------------  -----
 0   SEQDOCUMENTO  48027 non-null  int64
 1   ACORDAO       0 non-null      float64
 2   EMENTA        13 non-null     object
 3   RELATORIO     0 non-null      float64
 4   VOTO          0 non-null      float64
 5   DECISAO       48011 non-null  object
dtypes: float64(3), int64(1), object(2)
memory usage: 2.2+ MB
```

[12]:
```
dfDetalheDecisao.head(3)
```

[12]:
```
   SEQDOCUMENTO  ACORDAO EMENTA  RELATORIO  VOTO  \
0     309631639      NaN    NaN        NaN   NaN
1     310378377      NaN    NaN        NaN   NaN
2     309409286      NaN    NaN        NaN   NaN

                                             DECISAO
0  O presente pedido de contracautela tinha por o…
1  Trata-se de agravo em recurso especial interpo…
2  Trata-se de recurso especial interposto por MA…
```

[13]:
```
dfDetalheDecisao.drop(columns=['ACORDAO', 'EMENTA', 'RELATORIO', 'VOTO'],␣
 ↪inplace=True)
dfDetalheDecisao.head(3)
```

[13]:

	SEQDOCUMENTO	DECISAO
0	309631639	O presente pedido de contracautela tinha por o…
1	310378377	Trata-se de agravo em recurso especial interpo…
2	309409286	Trata-se de recurso especial interposto por MA…

##Redução dos registros com o intuito de reduzir o tempo no treinamento e verificar a curva de convergência

###Separar o número de processo pelo tipo (Aresp, HC).

[14]:
```
#field = "AREsp 2562174".split(" ")
#print(f"Tipo: '{field[0]}' Processo: '{field[1]}'  ")

dfMetaDadosDecisao['TIPOPROCESSO'] = dfMetaDadosDecisao['PROCESSO'].
 ↪apply(lambda tipoprocesso: tipoprocesso.split(" ")[0])
dfMetaDadosDecisao['NUMEROPROCESSO'] = dfMetaDadosDecisao['PROCESSO'].
 ↪apply(lambda numeroprocesso: numeroprocesso.split(" ")[1])
dfMetaDadosDecisao.drop(columns=['PROCESSO'], inplace=True, axis=1)

dfMetaDadosDecisao.head(3)
```

[14]:

	SEQDOCUMENTO	NUMEROREGISTRO	NM_MINISTRO	RECURSO	TEOR	\
0	309631639	202000946481	MARIA ISABEL GALLOTTI	NaN	Negando	
1	310378377	202400362531	JOÃO OTÁVIO DE NORONHA	NaN	Negando	
2	309409286	202401080738	MESSOD AZULAY NETO	NaN	Concedendo	

	DESCRICAOMONOCRATICA	TIPOPROCESSO	\
0	Prejudicada a ação de #{nome_da_parte} #{campo…	TP	
1	Conhecido o recurso de #{nome_da_parte} e não-…	AREsp	
2	Conhecido o recurso de #{nome_da_parte} e prov…	REsp	

	NUMEROPROCESSO
0	2695
1	2562174
2	2132967

[15]:
```
dfMetaDadosDecisao['TIPOPROCESSO'].value_counts()
```

[15]:

TIPOPROCESSO	
AREsp	27718
HC	9123
REsp	6650
CC	1956
RHC	1534

```
RMS              349
EAREsp           309
Rcl              235
EREsp            122
CR               121
ExeMS             97
MS                89
PUIL              69
Pet               68
TutCautAnt        35
AR                29
TutAntAnt         23
RvCr              21
SLS                8
HD                 7
Ag                 6
TP                 5
HDE                5
EmbExeMS           4
Prc                2
SS                 2
ExeAR              1
Name: count, dtype: int64
```

[16]:
```
# dfMetaDadosDecisao = dfMetaDadosDecisao[dfMetaDadosDecisao['TIPOPROCESSO'] ==
 ↪'REsp']
# dfMetaDadosDecisao.head(3)
```

[ ]:
```

```

##Sanitização do campo DECISAO

###Remoção de TAG's HTML do campo DECISAO e substituição por espaço em branco

[17]:
```
import re

def remove_html_tags(text):
    if isinstance(text, str):
        clean = re.compile('<.*?>')
        return re.sub(clean, ' ', text)
    return text
```

[18]:
```
dfDetalheDecisao['DECISAO'] = dfDetalheDecisao['DECISAO'].
 ↪apply(remove_html_tags)
display(dfDetalheDecisao.head())
```

	SEQDOCUMENTO	DECISAO
0	309631639	O presente pedido de contracautela tinha por o…
1	310378377	Trata-se de agravo em recurso especial interpo…

```
2     309409286  Trata-se de recurso especial interposto por MA…
3     310313783  Em agravo interposto contra decisão do Tribuna…
4     308791735  JOSIMAR TEOTONIO PONTES alega ser vítima de co…
```

###Remover STOP WORDS Motivação: https://medium.com/turing-talks/ferramentas-para-processamento-de-linguagem-natural-em-portugu%C3%AAs-977c7f59c382 Neste experimento, iremos remover o stop words, suspeitamos que tal acao prejudica o avaliacao contextual dos embeddings.

[19]:
```
import nltk

nltk.download('stopwords')

stopwords = nltk.corpus.stopwords.words('portuguese')
```

```
[nltk_data] Downloading package stopwords to
[nltk_data]     /home/alessandro.cporto/nltk_data…
[nltk_data]   Package stopwords is already up-to-date!
```

[20]:
```
import re
import nltk

nltk.download('stopwords')

def pre_processamento(texto):
    # Ensure texto is a string before processing
    if not isinstance(texto, str):
        return "" # Return empty string or handle non-string as appropriate

    # seleciona apenas letras
    letras =  re.findall(r'\b[A-zÀ-úü]+\b', texto) # Pass the text to findall

    # remove stopwords
    stopwords = nltk.corpus.stopwords.words('portuguese')
    stop = set(stopwords)
    sem_stopwords = [w for w in letras if w.lower() not in stop] # Use lower()␣
 ↪for case-insensitive stopword removal

    # juntando os tokens novamente em formato de texto
    texto_limpo = " ".join(sem_stopwords)

    return texto_limpo
```

```
[nltk_data] Downloading package stopwords to
[nltk_data]     /home/alessandro.cporto/nltk_data…
[nltk_data]   Package stopwords is already up-to-date!
```

[21]:
```
#Exemplo de uso da função
```

```
texto = """Trata-se dehabeas corpussubstitutivo de recurso próprio, com pedido␣
 ↪de liminar, impetrado em favor deLUIS FELIPE SILVA DE ASSIS, em que se␣
 ↪aponta com autoridade coatora o Tribunal de Justiça do Estado do Rio de␣
 ↪Janeiro.Consta dos autos que o paciente foi condenado à pena de 5 anos e 10␣
 ↪meses de reclusão, em regime semiaberto, mais pagamento de 583 dias-multa,␣
 ↪como incurso no art. 33,caput, c.c o 40, VI, da Lei n. 11.343/2006.Em sede␣
 ↪recursal, o Tribunal de origem negou provimento ao apelo defensivo"""
texto = pre_processamento(texto)

print(texto)
```

```
Trata dehabeas corpussubstitutivo recurso próprio pedido liminar impetrado favor
deLUIS FELIPE SILVA ASSIS aponta autoridade coatora Tribunal Justiça Estado Rio
Janeiro Consta autos paciente condenado pena anos meses reclusão regime
semiaberto pagamento dias multa incurso art caput c c VI Lei n sede recursal
Tribunal origem negou provimento apelo defensivo
```

[22]:
```
# Neste experimento, sera mantida as STOP_WORDS para verificar se o␣
 ↪comportamento com os embeddings e melhor.
# dfDetalheDecisao['DECISAO'] = dfDetalheDecisao['DECISAO'].
 ↪apply(pre_processamento)
```

[23]:
```
import re

def remove_extra_spaces(text):
    if isinstance(text, str):
        # Replace multiple whitespace characters (spaces, tabs, newlines) with␣
 ↪a single space
        return re.sub(r'\s+', ' ', text).strip()
    return text
```

[24]:
```
#Exemplo de uso da função
texto = """   Trata-se  dehabeas   corpussubstitutivo    de
recurso          próprio, com pedido de liminar."""
texto = remove_extra_spaces(texto)

print(texto)
```

```
Trata-se dehabeas corpussubstitutivo de recurso próprio, com pedido de liminar.
```

[25]:
```
dfDetalheDecisao['DECISAO'] = dfDetalheDecisao['DECISAO'].
 ↪apply(remove_extra_spaces)
```

###Junção dos Datasets em um único dataset

[26]:
```
def get_decisao(seq_documento):
    # Filter dfDetalheAcordaos for the given SEQDOCUMENTO
```

```
    decisao_row = dfDetalheDecisao[dfDetalheDecisao['SEQDOCUMENTO'] ==␣
 ↪seq_documento]

    # Check if the filtered DataFrame is empty
    if not decisao_row.empty:
        # If not empty, return the 'ACORDAO' value
        return decisao_row.head(1)['DECISAO'].iloc[0]
    else:
        # If empty, return None
        return None

def get_tipo_decisao(teor_decisao):
    # Filter dfDetalheAcordaos for the given SEQDOCUMENTO
    tipo_decisao_row = dfTipoDecisao[dfTipoDecisao['DESC_TEOR_DECISAO'] ==␣
 ↪teor_decisao].head(1)

    # Check if the filtered DataFrame is empty
    if not tipo_decisao_row.empty:
        # If not empty, return the 'ACORDAO' value
        return tipo_decisao_row.head(1)['DECISAO_FAVORAVEL'].iloc[0]
    else:
        # If empty, return None
        return None
```

[27]:
```
dfMetaDadosDecisao['DECISAO']  = dfMetaDadosDecisao['SEQDOCUMENTO'].
 ↪apply(get_decisao)
dfMetaDadosDecisao['DECISAO_FAVORAVEL']  = dfMetaDadosDecisao['TEOR'].
 ↪apply(get_tipo_decisao)
```

[28]:
```
dfMetaDadosDecisao.head(3)
```

[28]:

	SEQDOCUMENTO	NUMEROREGISTRO	NM_MINISTRO RECURSO	TEOR	DESCRICAOMONOCRATICA	TIPOPROCESSO	NUMEROPROCESSO	DECISAO	DECISAO_FAVORAVEL
0	309631639	202000946481	MARIA ISABEL GALLOTTI	NaN	Negando	Prejudicada a ação de #{nome_da_parte} #{campo…	TP	2695	O presente pedido de contracautela tinha por o…	
1	310378377	202400362531	JOÃO OTÁVIO DE NORONHA	NaN	Negando	Conhecido o recurso de #{nome_da_parte} e não-…	AREsp	2562174	Trata-se de agravo em recurso especial interpo…	
2	309409286	202401080738	MESSOD AZULAY NETO	NaN	Concedendo	Conhecido o recurso de #{nome_da_parte} e prov…	REsp	2132967	Trata-se de recurso especial interposto por MA…	

```
0                 N
1                 N
2                 S
```

[29]:
```
# Filter rows where 'TEOR' is not empty (NaN) and assign to a new dataframe
dfMetaDadosDecisao_filtered = dfMetaDadosDecisao.dropna(subset=['TEOR']).copy()

# Filter rows where 'DECISAO' is not empty (NaN) and assign to a new dataframe
dfMetaDadosDecisao_filtered = dfMetaDadosDecisao_filtered.
 ↪dropna(subset=['DECISAO']).copy()

# Filter rows where 'DECISAO_FAVORAVEL is not empty (NaN) and assign to a new␣
 ↪dataframe -- decisões neutras não possuem efeito jurídico considerável
dfMetaDadosDecisao_filtered = dfMetaDadosDecisao_filtered.
 ↪dropna(subset=['DECISAO_FAVORAVEL']).copy()

dfMetaDadosDecisao = dfMetaDadosDecisao_filtered
dfMetaDadosDecisao.head(5)
```

[29]:
```
   SEQDOCUMENTO  NUMEROREGISTRO  \
0     309631639    202000946481
1     310378377    202400362531
2     309409286    202401080738
3     310313783    202403756009
4     308791735    202500051465

                                        NM_MINISTRO RECURSO            TEOR  \
0                             MARIA ISABEL GALLOTTI     NaN         Negando
1                            JOÃO OTÁVIO DE NORONHA     NaN         Negando
2                               MESSOD AZULAY NETO     NaN      Concedendo
3  CARLOS CINI MARCHIONATTI (DESEMBARGADOR CONVOC…     NaN  Não Conhecendo
4                             ROGERIO SCHIETTI CRUZ     NaN         Negando

                              DESCRICAOMONOCRATICA TIPOPROCESSO  \
0  Prejudicada a ação de #{nome_da_parte} #{campo…           TP
1  Conhecido o recurso de #{nome_da_parte} e não-…        AREsp
2  Conhecido o recurso de #{nome_da_parte} e prov…         REsp
3  Não conhecido o recurso de #{nome_da_parte} #{…        AREsp
4  Denegado o Habeas Corpus de #{nome_da_parte} #…           HC

  NUMEROPROCESSO                                           DECISAO  \
0           2695  O presente pedido de contracautela tinha por o…
1        2562174  Trata-se de agravo em recurso especial interpo…
2        2132967  Trata-se de recurso especial interposto por MA…
3        2761478  Em agravo interposto contra decisão do Tribuna…
4         973936  JOSIMAR TEOTONIO PONTES alega ser vítima de co…
```

```
  DECISAO_FAVORAVEL
0                 N
1                 N
2                 S
3                 N
4                 N
```

[30]:
```
dfMetaDadosDecisao.head()
```

[30]:
```
   SEQDOCUMENTO  NUMEROREGISTRO  \
0     309631639    202000946481
1     310378377    202400362531
2     309409286    202401080738
3     310313783    202403756009
4     308791735    202500051465

                                          NM_MINISTRO RECURSO            TEOR  \
0                            MARIA ISABEL GALLOTTI     NaN         Negando
1                           JOÃO OTÁVIO DE NORONHA     NaN         Negando
2                              MESSOD AZULAY NETO     NaN      Concedendo
3  CARLOS CINI MARCHIONATTI (DESEMBARGADOR CONVOC…     NaN  Não Conhecendo
4                            ROGERIO SCHIETTI CRUZ     NaN         Negando

                               DESCRICAOMONOCRATICA TIPOPROCESSO  \
0  Prejudicada a ação de #{nome_da_parte} #{campo…           TP
1  Conhecido o recurso de #{nome_da_parte} e não-…        AREsp
2  Conhecido o recurso de #{nome_da_parte} e prov…         REsp
3  Não conhecido o recurso de #{nome_da_parte} #{…        AREsp
4  Denegado o Habeas Corpus de #{nome_da_parte} #…           HC

  NUMEROPROCESSO                                          DECISAO  \
0           2695  O presente pedido de contracautela tinha por o…
1        2562174  Trata-se de agravo em recurso especial interpo…
2        2132967  Trata-se de recurso especial interposto por MA…
3        2761478  Em agravo interposto contra decisão do Tribuna…
4         973936  JOSIMAR TEOTONIO PONTES alega ser vítima de co…

  DECISAO_FAVORAVEL
0                 N
1                 N
2                 S
3                 N
4                 N
```

0.0.1 Junção dos campos DESCRICAOMONOCRATICA com DECISAO

Estudar a possibilidade de dar maior atenção à decisão monocrática.

[31]:
```
dfMetaDadosDecisao.head(3)
```

[31]:
```
   SEQDOCUMENTO  NUMEROREGISTRO             NM_MINISTRO RECURSO        TEOR  \
0     309631639    202000946481   MARIA ISABEL GALLOTTI     NaN     Negando
1     310378377    202400362531  JOÃO OTÁVIO DE NORONHA     NaN     Negando
2     309409286    202401080738      MESSOD AZULAY NETO     NaN  Concedendo

                               DESCRICAOMONOCRATICA TIPOPROCESSO  \
0  Prejudicada a ação de #{nome_da_parte} #{campo…           TP
1  Conhecido o recurso de #{nome_da_parte} e não-…        AREsp
2  Conhecido o recurso de #{nome_da_parte} e prov…         REsp

  NUMEROPROCESSO                                           DECISAO  \
0           2695  O presente pedido de contracautela tinha por o…
1        2562174  Trata-se de agravo em recurso especial interpo…
2        2132967  Trata-se de recurso especial interposto por MA…

  DECISAO_FAVORAVEL
0                 N
1                 N
2                 S
```

##Análise de dados após tratamento

[32]:
```
dfMetaDadosDecisao['DECISAOCOMPLETA'] =␣
↪dfMetaDadosDecisao['DESCRICAOMONOCRATICA'] + ' -- ' +␣
↪dfMetaDadosDecisao['DECISAO']
```

###Verificando distribuição de dados entre as decisões favoráveis ou não ao réu

####Consulta direta no tipo de decisão (Favorável ou não)

[33]:
```
#dfMetaDadosDecisao['DECISAOCOMPLETA'][283]
```

[34]:
```
dfMetaDadosDecisao_filtered[dfMetaDadosDecisao_filtered['DECISAO_FAVORAVEL'] ␣
↪== 'N'].head(5)
```

[34]:
```
   SEQDOCUMENTO  NUMEROREGISTRO  \
0     309631639    202000946481
1     310378377    202400362531
3     310313783    202403756009
4     308791735    202500051465
5     310057660    202501165811

                                        NM_MINISTRO RECURSO            TEOR  \
0                            MARIA ISABEL GALLOTTI     NaN         Negando
1                           JOÃO OTÁVIO DE NORONHA     NaN         Negando
3  CARLOS CINI MARCHIONATTI (DESEMBARGADOR CONVOC…     NaN  Não Conhecendo
4                            ROGERIO SCHIETTI CRUZ     NaN         Negando
```

```
5                                  HERMAN BENJAMIN     NaN  Não Conhecendo

                                DESCRICAOMONOCRATICA TIPOPROCESSO  \
0  Prejudicada a ação de #{nome_da_parte} #{campo…           TP
1  Conhecido o recurso de #{nome_da_parte} e não-…        AREsp
3  Não conhecido o recurso de #{nome_da_parte} #{…        AREsp
4  Denegado o Habeas Corpus de #{nome_da_parte} #…           HC
5  Não conhecido o recurso de #{nome_da_parte} #{…        AREsp

  NUMEROPROCESSO                                              DECISAO  \
0           2695  O presente pedido de contracautela tinha por o…
1        2562174  Trata-se de agravo em recurso especial interpo…
3        2761478  Em agravo interposto contra decisão do Tribuna…
4         973936  JOSIMAR TEOTONIO PONTES alega ser vítima de co…
5        2899900  Cuida-se de Agravo em Recurso Especial apresen…

  DECISAO_FAVORAVEL                                    DECISAOCOMPLETA
0                 N  Prejudicada a ação de #{nome_da_parte} #{campo…
1                 N  Conhecido o recurso de #{nome_da_parte} e não-…
3                 N  Não conhecido o recurso de #{nome_da_parte} #{…
4                 N  Denegado o Habeas Corpus de #{nome_da_parte} #…
5                 N  Não conhecido o recurso de #{nome_da_parte} #{…
```

[35]:
```
dfMetaDadosDecisao_filtered.shape
```

[35]:
```
(48011, 11)
```

####Verificando distribuição dos dados propriamente dita

[36]:
```
dataset = dfMetaDadosDecisao

total   = dataset.shape[0]
label_s = dfMetaDadosDecisao_filtered[dataset['DECISAO_FAVORAVEL']  == 'S'].
 ↪shape[0]
label_n = dfMetaDadosDecisao_filtered[dataset['DECISAO_FAVORAVEL']  == 'N'].
 ↪shape[0]

print(f'TOTAL  : {total}')
print(f'LABEL S: {label_s} - % {round(label_s/total*100, 2)}')
print(f'LABEL N: {label_n} - % {round(label_n/total*100, 2)}')
```

```
TOTAL  : 48011
LABEL S: 7402 - % 15.42
LABEL N: 40609 - % 84.58
```

##Preparação dos dados para Treinamento

###Separando entre dados de treinamento e teste

[37]:
```
from sklearn.model_selection import train_test_split

# Separate features (X) and target (y)
X = dataset.drop('DECISAO_FAVORAVEL', axis=1)
y = dataset['DECISAO_FAVORAVEL']

# Split the data into training and testing sets, stratifying by␣
 ↪'DECISAO_FAVORAVEL'
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.35,␣
 ↪random_state=42, stratify=y)

print("Training set shape (X_train, y_train):", X_train.shape, y_train.shape)
print("Testing set shape (X_test, y_test):", X_test.shape, y_test.shape)

# Display the distribution of 'DECISAO_FAVORAVEL' in the original dataset,␣
 ↪training set, and testing set
print("\nOriginal dataset 'DECISAO_FAVORAVEL' distribution:")
display(y.value_counts(normalize=True))

print("\nTraining set 'DECISAO_FAVORAVEL' distribution:")
display(y_train.value_counts(normalize=True))

print("\nTesting set 'DECISAO_FAVORAVEL' distribution:")
display(y_test.value_counts(normalize=True))
```

```
Training set shape (X_train, y_train): (31207, 10) (31207,)
Testing set shape (X_test, y_test): (16804, 10) (16804,)

Original dataset 'DECISAO_FAVORAVEL' distribution:

DECISAO_FAVORAVEL
N    0.845827
S    0.154173
Name: proportion, dtype: float64


Training set 'DECISAO_FAVORAVEL' distribution:

DECISAO_FAVORAVEL
N    0.845836
S    0.154164
Name: proportion, dtype: float64


Testing set 'DECISAO_FAVORAVEL' distribution:

DECISAO_FAVORAVEL
N    0.845811
S    0.154189
Name: proportion, dtype: float64
```

[38]:
```
#dataframeGhost['gasper'] = 0
```

###Selecionando modelo pre-treinado e realizando tokenização

[39]:
```
from transformers import AutoTokenizer, AutoModelForSequenceClassification # Or␣
↪BertTokenizer, BertForSequenceClassification

model_checkpoint = 'neuralmind/bert-base-portuguese-cased'

model = AutoModelForSequenceClassification.from_pretrained(model_checkpoint,␣
↪num_labels=2) # Use AutoModelForSequenceClassification
tokenizer = AutoTokenizer.from_pretrained(model_checkpoint, do_lower_case=False)
```

```
2025-11-13 13:55:10.117744: I tensorflow/core/util/port.cc:153] oneDNN custom
operations are on. You may see slightly different numerical results due to
floating-point round-off errors from different computation orders. To turn them
off, set the environment variable `TF_ENABLE_ONEDNN_OPTS=0`.
2025-11-13 13:55:11.658286: I tensorflow/core/platform/cpu_feature_guard.cc:210]
This TensorFlow binary is optimized to use available CPU instructions in
performance-critical operations.
To enable the following instructions: AVX2 AVX512F AVX512_VNNI FMA, in other
operations, rebuild TensorFlow with the appropriate compiler flags.
2025-11-13 13:55:15.190761: I tensorflow/core/util/port.cc:153] oneDNN custom
operations are on. You may see slightly different numerical results due to
floating-point round-off errors from different computation orders. To turn them
off, set the environment variable `TF_ENABLE_ONEDNN_OPTS=0`.
Some weights of BertForSequenceClassification were not initialized from the
model checkpoint at neuralmind/bert-base-portuguese-cased and are newly
initialized: ['classifier.bias', 'classifier.weight']
You should probably TRAIN this model on a down-stream task to be able to use it
for predictions and inference.
```

[40]:
```
from transformers import DataCollatorWithPadding
from datasets import Dataset # Import Dataset

# Pad to the longest sequence in the batch
data_collator = DataCollatorWithPadding(tokenizer=tokenizer)

def preprocess_function(batches):
   """Tokenize input data"""
   return tokenizer(batches["DECISAO"], max_length=512, truncation=True) # Use␣
↪"DECISAO" as the column name

# Convert pandas Series to Hugging Face Dataset
train_dataset = Dataset.from_pandas(X_train)
test_dataset = Dataset.from_pandas(X_test)

# Convert labels to integers
```

```
'''
The Hugging Face Trainer usually requires integer labels for classification.
I will convert the string labels ('S' and 'N') to integers (e.g., 0 and 1)␣
 ↪before
adding them to the dataset.
'''
label_map = {'N': 0, 'S': 1}
y_train_encoded = y_train.map(label_map)
y_test_encoded = y_test.map(label_map)

# Add labels to the datasets
train_dataset = train_dataset.add_column("labels", y_train_encoded.tolist())
test_dataset = test_dataset.add_column("labels", y_test_encoded.tolist())

# Tokenize train/test data using the Dataset map method
tokenized_train = train_dataset.map(preprocess_function, batched=True)
tokenized_test = test_dataset.map(preprocess_function, batched=True)
```

```
Map:   0%|          | 0/31207 [00:00<?, ? examples/s]
```

```
Map:   0%|          | 0/16804 [00:00<?, ? examples/s]
```

[41]:
```
#Show diferences between standard dataset and pandas dataset.
train_dataset['labels']
```

[41]:
```
Column([0, 0, 0, 0, 1])
```

[42]:
```
%%capture
if not install_evaluate:
  install_evaluate = True
  %pip install evaluate
```

```
huggingface/tokenizers: The current process just got forked, after parallelism
has already been used. Disabling parallelism to avoid deadlocks…
To disable this warning, you can either:
        - Avoid using `tokenizers` before the fork if possible
        - Explicitly set the environment variable TOKENIZERS_PARALLELISM=(true |
false)
```

###Definindo método para averiguar a qualidade do modelo (métrica de avaliação)

[43]:
```
import numpy as np
import evaluate

def compute_metrics(eval_pred):
    """Calculate F1 score"""
    logits, labels = eval_pred
    predictions = np.argmax(logits, axis=-1)
```

```
    load_f1 = evaluate.load("f1")
    f1 = load_f1.compute(predictions=predictions, references=labels)["f1"]
    return {"f1": f1}
```

[44]:
```
import sys

def get_avg_epoch_time(log_history: list) -> float | None:
    """
    Calcula o tempo médio por época (em minutos) a partir do
    log_history do Hugging Face Trainer.

    Args:
        log_history (list): Uma lista de dicionários, que é o
                            trainer.state.log_history.

    Returns:
        float: O tempo médio por época em minutos.
        None: Se os dados necessários não forem encontrados no histórico.
    """

    # 1. Encontrar o log de resumo do treino.
    #    Iteramos de trás para frente, pois o resumo é sempre um dos
    #    últimos itens logados.
    train_summary = None
    for log in reversed(log_history):
        if 'train_runtime' in log:
            train_summary = log
            break  # Encontramos o log que queremos

    # 2. Verificar se encontramos o log
    if train_summary is None:
        print("Erro: 'train_runtime' não foi encontrado no histórico de logs.",␣
↪file=sys.stderr)
        return None

    # 3. Extrair os dados necessários
    # Usamos .get() para evitar erros caso a chave não exista
    total_seconds = train_summary.get('train_runtime')
    total_epochs = train_summary.get('epoch')

    # 4. Validar os dados
    if total_seconds is None or total_epochs is None:
        print("Erro: 'train_runtime' ou 'epoch' estão faltando no log de resumo.
↪", file=sys.stderr)
        return None

    if total_epochs == 0:
```

```
        print("Erro: O número total de épocas é zero. Divisão por zero evitada.
↪", file=sys.stderr)
        return None

    # 5. Calcular e retornar o tempo em minutos
    seconds_per_epoch = total_seconds / total_epochs
    minutes_per_epoch = seconds_per_epoch / 60

    return minutes_per_epoch
```

[45]:
```
# X_train['Exception Please']
```

[46]:
```
# # Print layer names
# i = 0
# for name, param in model.named_parameters():
#   i = i +1
#   print(f"index: {i} {name}")
```

[47]:
```
# Encoder block 10 starts at index 165 and
# we freeze everything before that block
# for index, (name, param) in enumerate(model.named_parameters()):
#     if index < 165:
#         param.requires_grad = False
```

###Preparação do modelo

[48]:
```
%%capture
!pip install tf_keras
```

```
huggingface/tokenizers: The current process just got forked, after parallelism
has already been used. Disabling parallelism to avoid deadlocks…
To disable this warning, you can either:
        - Avoid using `tokenizers` before the fork if possible
        - Explicitly set the environment variable TOKENIZERS_PARALLELISM=(true |
false)
```

[49]:
```
# %%capture
# !pip install 'accelerate>=0.26.0'
```

[ ]:
```

```

[50]:
```
# %%capture
# !pip install transformers[torch]
```

[51]:
```
# This is the line that gets the device
device = torch.device("cuda" if torch.cuda.is_available() else "cpu")

print(f"Using device: {device}")
```

```
Using device: cuda
```

[52]:
```python
from transformers import TrainingArguments, Trainer
import torch # Import torch

EPOCHS = 100
APPROACH_EXECUTION = 'epoch'

# Training arguments for parameter tuning
if APPROACH_EXECUTION == 'epoch':
    training_args = TrainingArguments(
       "model",
       learning_rate= 2e-5,
       per_device_train_batch_size=16,
       per_device_eval_batch_size=16,
       num_train_epochs=EPOCHS,
       weight_decay=0.01,
       save_strategy="epoch",
       logging_strategy="epoch",
       report_to="none",
    )
else:#step
    training_args = TrainingArguments(
       "model",
       learning_rate= 1e-5,
       per_device_train_batch_size=32,
       per_device_eval_batch_size=32,
       num_train_epochs=EPOCHS,
       weight_decay=0.01,
       save_strategy="steps",
       eval_steps=100, # Evaluate every 100 steps
       logging_steps=100, # Log every 100 steps
       report_to="none",
       load_best_model_at_end=True, # Load the best model (based on metric) at␣
 ↪the end of training
       metric_for_best_model="f1", # Metric to monitor for best model selection
       greater_is_better=True, # A higher F1 score is better
    )
```

[53]:
```python
# Trainer which executes the training process
trainer = Trainer(
   model=model,
   args=training_args,
   train_dataset=tokenized_train,
   eval_dataset=tokenized_test,
   tokenizer=tokenizer,
   data_collator=data_collator,
```

```
    compute_metrics=compute_metrics,
)
```

```
/tmp/ipykernel_18167/2254602729.py:2: FutureWarning: `tokenizer` is deprecated
and will be removed in version 5.0.0 for `Trainer.__init__`. Use
`processing_class` instead.
  trainer = Trainer(
```

###Treinamento

[54]:
```
import datetime
import time

def format_duration(td: datetime.timedelta) -> str:
    """Formata um objeto timedelta em HH:MM:SS."""
    total_seconds = int(td.total_seconds())
    hours = total_seconds // 3600
    minutes = (total_seconds % 3600) // 60
    seconds = total_seconds % 60
    # Retorna no formato 00:00:00
    return f"{hours:02}:{minutes:02}:{seconds:02}"
```

[55]:
```
start_time = datetime.datetime.now()

start_time_str = start_time.strftime("%H:%M:%S")
print(f"  Processo iniciado em: {start_time_str}")

trainer.train()

end_time = datetime.datetime.now()
end_time_str = end_time.strftime("%H:%M:%S")
print(f"Processo finalizado em: {end_time_str}")

# --- 4. Calcular e imprimir a duração ---
duration = end_time - start_time

print("\n--- Resumo da Duração ---")
# Imprime o objeto timedelta (pode incluir microssegundos)
print(f"Duração (Objeto): {duration}")

# Imprime o total de segundos
print(f"Duração (Segundos): {duration.total_seconds():.2f} s")

# Imprime no formato HH:MM:SS
print(f"Duração (Formatada): {format_duration(duration)}")
print(f'Media de execucao por epoca: {round(get_avg_epoch_time(trainer.state.
 ↪log_history),2) } min.')
```

```
 Processo iniciado em: 13:56:24
```

```
<IPython.core.display.HTML object>

Processo finalizado em: 15:39:25


--- Resumo da Duração ---
Duração (Objeto): 1 day, 1:43:01.937209
Duração (Segundos): 92581.94 s
Duração (Formatada): 25:43:01
Media de execucao por epoca: 15.43 min.
```

##Avaliação do modelo

[56]:
```
trainer.state.log_history
```

[56]:
```
[{'loss': 0.2709,
  'grad_norm': 5.453711032867432,
  'learning_rate': 1.9800102511532547e-05,
  'epoch': 1.0,
  'step': 1951},
 {'loss': 0.2151,
  'grad_norm': 10.034995079040527,
  'learning_rate': 1.960010251153255e-05,
  'epoch': 2.0,
  'step': 3902},
 {'loss': 0.1858,
  'grad_norm': 2.9000210762023926,
  'learning_rate': 1.9400102511532548e-05,
  'epoch': 3.0,
  'step': 5853},
 {'loss': 0.1563,
  'grad_norm': 0.22712670266628265,
  'learning_rate': 1.9200102511532546e-05,
  'epoch': 4.0,
  'step': 7804},
 {'loss': 0.1272,
  'grad_norm': 1.855729341506958,
  'learning_rate': 1.900010251153255e-05,
  'epoch': 5.0,
  'step': 9755},
 {'loss': 0.1027,
  'grad_norm': 0.4103025496006012,
  'learning_rate': 1.880010251153255e-05,
  'epoch': 6.0,
  'step': 11706},
 {'loss': 0.081,
  'grad_norm': 0.05742510035634041,
  'learning_rate': 1.860010251153255e-05,
  'epoch': 7.0,
```

```
 'step': 13657},
{'loss': 0.0664,
 'grad_norm': 0.04940146580338478,
 'learning_rate': 1.840010251153255e-05,
 'epoch': 8.0,
 'step': 15608},
{'loss': 0.0528,
 'grad_norm': 0.09320738166570663,
 'learning_rate': 1.820010251153255e-05,
 'epoch': 9.0,
 'step': 17559},
{'loss': 0.0467,
 'grad_norm': 0.2016042023897171,
 'learning_rate': 1.8000102511532548e-05,
 'epoch': 10.0,
 'step': 19510},
{'loss': 0.0438,
 'grad_norm': 0.44957277178764343,
 'learning_rate': 1.780010251153255e-05,
 'epoch': 11.0,
 'step': 21461},
{'loss': 0.0355,
 'grad_norm': 0.042008254677057266,
 'learning_rate': 1.7600102511532548e-05,
 'epoch': 12.0,
 'step': 23412},
{'loss': 0.0339,
 'grad_norm': 44.53449249267578,
 'learning_rate': 1.740010251153255e-05,
 'epoch': 13.0,
 'step': 25363},
{'loss': 0.029,
 'grad_norm': 0.15516547858715057,
 'learning_rate': 1.720010251153255e-05,
 'epoch': 14.0,
 'step': 27314},
{'loss': 0.0303,
 'grad_norm': 0.0019687942694872618,
 'learning_rate': 1.7000102511532547e-05,
 'epoch': 15.0,
 'step': 29265},
{'loss': 0.0238,
 'grad_norm': 0.03557153418660164,
 'learning_rate': 1.680010251153255e-05,
 'epoch': 16.0,
 'step': 31216},
{'loss': 0.0259,
```

```
 'grad_norm': 0.12015185505151749,
 'learning_rate': 1.660010251153255e-05,
 'epoch': 17.0,
 'step': 33167},
{'loss': 0.0217,
 'grad_norm': 0.0015645120292901993,
 'learning_rate': 1.640010251153255e-05,
 'epoch': 18.0,
 'step': 35118},
{'loss': 0.0202,
 'grad_norm': 0.0004076276964042336,
 'learning_rate': 1.6200102511532548e-05,
 'epoch': 19.0,
 'step': 37069},
{'loss': 0.0196,
 'grad_norm': 0.029314406216144562,
 'learning_rate': 1.600010251153255e-05,
 'epoch': 20.0,
 'step': 39020},
{'loss': 0.0192,
 'grad_norm': 0.2060929536819458,
 'learning_rate': 1.5800102511532548e-05,
 'epoch': 21.0,
 'step': 40971},
{'loss': 0.0145,
 'grad_norm': 0.0007412490667775273,
 'learning_rate': 1.560010251153255e-05,
 'epoch': 22.0,
 'step': 42922},
{'loss': 0.0201,
 'grad_norm': 0.0024364632554352283,
 'learning_rate': 1.540010251153255e-05,
 'epoch': 23.0,
 'step': 44873},
{'loss': 0.0155,
 'grad_norm': 0.0015715558547526598,
 'learning_rate': 1.5200102511532549e-05,
 'epoch': 24.0,
 'step': 46824},
{'loss': 0.0104,
 'grad_norm': 0.00034900926402769983,
 'learning_rate': 1.5000102511532547e-05,
 'epoch': 25.0,
 'step': 48775},
{'loss': 0.0115,
 'grad_norm': 0.0004681822028942406,
 'learning_rate': 1.4800102511532548e-05,
```

```
 'epoch': 26.0,
 'step': 50726},
{'loss': 0.0134,
 'grad_norm': 0.004886557813733816,
 'learning_rate': 1.4600102511532548e-05,
 'epoch': 27.0,
 'step': 52677},
{'loss': 0.0143,
 'grad_norm': 0.0008537113899365067,
 'learning_rate': 1.4400102511532548e-05,
 'epoch': 28.0,
 'step': 54628},
{'loss': 0.0104,
 'grad_norm': 0.002974109258502722,
 'learning_rate': 1.4200102511532547e-05,
 'epoch': 29.0,
 'step': 56579},
{'loss': 0.0104,
 'grad_norm': 0.0006495919078588486,
 'learning_rate': 1.400010251153255e-05,
 'epoch': 30.0,
 'step': 58530},
{'loss': 0.0116,
 'grad_norm': 0.0017630441579967737,
 'learning_rate': 1.3800102511532549e-05,
 'epoch': 31.0,
 'step': 60481},
{'loss': 0.011,
 'grad_norm': 0.06485091149806976,
 'learning_rate': 1.3600102511532549e-05,
 'epoch': 32.0,
 'step': 62432},
{'loss': 0.0083,
 'grad_norm': 0.002959929872304201,
 'learning_rate': 1.340010251153255e-05,
 'epoch': 33.0,
 'step': 64383},
{'loss': 0.0099,
 'grad_norm': 0.0002850918099284172,
 'learning_rate': 1.320010251153255e-05,
 'epoch': 34.0,
 'step': 66334},
{'loss': 0.0079,
 'grad_norm': 0.0004477894108276814,
 'learning_rate': 1.3000102511532548e-05,
 'epoch': 35.0,
 'step': 68285},
```

```
{'loss': 0.0082,
 'grad_norm': 0.0004895225865766406,
 'learning_rate': 1.2800102511532548e-05,
 'epoch': 36.0,
 'step': 70236},
{'loss': 0.008,
 'grad_norm': 0.0004935848992317915,
 'learning_rate': 1.2600102511532548e-05,
 'epoch': 37.0,
 'step': 72187},
{'loss': 0.0064,
 'grad_norm': 0.002250398276373744,
 'learning_rate': 1.2400102511532549e-05,
 'epoch': 38.0,
 'step': 74138},
{'loss': 0.0097,
 'grad_norm': 81.21642303466797,
 'learning_rate': 1.2200102511532547e-05,
 'epoch': 39.0,
 'step': 76089},
{'loss': 0.0076,
 'grad_norm': 0.00020544012659229338,
 'learning_rate': 1.2000102511532547e-05,
 'epoch': 40.0,
 'step': 78040},
{'loss': 0.0086,
 'grad_norm': 0.00031750689959153533,
 'learning_rate': 1.1800102511532548e-05,
 'epoch': 41.0,
 'step': 79991},
{'loss': 0.0041,
 'grad_norm': 0.00016831030370667577,
 'learning_rate': 1.160010251153255e-05,
 'epoch': 42.0,
 'step': 81942},
{'loss': 0.006,
 'grad_norm': 0.00013767665950581431,
 'learning_rate': 1.140010251153255e-05,
 'epoch': 43.0,
 'step': 83893},
{'loss': 0.008,
 'grad_norm': 0.00014342632493935525,
 'learning_rate': 1.1200102511532548e-05,
 'epoch': 44.0,
 'step': 85844},
{'loss': 0.0034,
 'grad_norm': 0.00013395446876529604,
```

```
 'learning_rate': 1.1000102511532549e-05,
 'epoch': 45.0,
 'step': 87795},
{'loss': 0.0049,
 'grad_norm': 0.00014817675400990993,
 'learning_rate': 1.0800102511532549e-05,
 'epoch': 46.0,
 'step': 89746},
{'loss': 0.0061,
 'grad_norm': 0.00026669466751627624,
 'learning_rate': 1.0600102511532549e-05,
 'epoch': 47.0,
 'step': 91697},
{'loss': 0.0049,
 'grad_norm': 0.00014709681272506714,
 'learning_rate': 1.0400102511532547e-05,
 'epoch': 48.0,
 'step': 93648},
{'loss': 0.0051,
 'grad_norm': 0.0002799293433781713,
 'learning_rate': 1.0200102511532548e-05,
 'epoch': 49.0,
 'step': 95599},
{'loss': 0.0044,
 'grad_norm': 0.0004747720086015761,
 'learning_rate': 1.0000102511532548e-05,
 'epoch': 50.0,
 'step': 97550},
{'loss': 0.0051,
 'grad_norm': 0.002294270321726799,
 'learning_rate': 9.800102511532548e-06,
 'epoch': 51.0,
 'step': 99501},
{'loss': 0.0043,
 'grad_norm': 0.0004604579880833626,
 'learning_rate': 9.600102511532548e-06,
 'epoch': 52.0,
 'step': 101452},
{'loss': 0.0039,
 'grad_norm': 0.0004043464723508805,
 'learning_rate': 9.400102511532549e-06,
 'epoch': 53.0,
 'step': 103403},
{'loss': 0.004,
 'grad_norm': 0.00012029591744067147,
 'learning_rate': 9.200102511532549e-06,
 'epoch': 54.0,
```

```
 'step': 105354},
{'loss': 0.003,
 'grad_norm': 0.00014121491403784603,
 'learning_rate': 9.000102511532547e-06,
 'epoch': 55.0,
 'step': 107305},
{'loss': 0.0039,
 'grad_norm': 0.0042517404071986675,
 'learning_rate': 8.800102511532548e-06,
 'epoch': 56.0,
 'step': 109256},
{'loss': 0.0037,
 'grad_norm': 0.006666805129498243,
 'learning_rate': 8.600102511532548e-06,
 'epoch': 57.0,
 'step': 111207},
{'loss': 0.0032,
 'grad_norm': 0.0004974825424142182,
 'learning_rate': 8.400102511532548e-06,
 'epoch': 58.0,
 'step': 113158},
{'loss': 0.003,
 'grad_norm': 7.916837785160169e-05,
 'learning_rate': 8.200102511532548e-06,
 'epoch': 59.0,
 'step': 115109},
{'loss': 0.0046,
 'grad_norm': 0.00010523812670726329,
 'learning_rate': 8.000102511532548e-06,
 'epoch': 60.0,
 'step': 117060},
{'loss': 0.0022,
 'grad_norm': 0.00033406325383111835,
 'learning_rate': 7.800102511532549e-06,
 'epoch': 61.0,
 'step': 119011},
{'loss': 0.0032,
 'grad_norm': 0.00018441362772136927,
 'learning_rate': 7.600102511532548e-06,
 'epoch': 62.0,
 'step': 120962},
{'loss': 0.0007,
 'grad_norm': 0.00012026696640532464,
 'learning_rate': 7.400102511532547e-06,
 'epoch': 63.0,
 'step': 122913},
{'loss': 0.0019,
```

```
 'grad_norm': 7.879847544245422e-05,
 'learning_rate': 7.2001025115325485e-06,
 'epoch': 64.0,
 'step': 124864},
{'loss': 0.0031,
 'grad_norm': 9.830277122091502e-05,
 'learning_rate': 7.000102511532549e-06,
 'epoch': 65.0,
 'step': 126815},
{'loss': 0.0019,
 'grad_norm': 0.00010666371963452548,
 'learning_rate': 6.800102511532548e-06,
 'epoch': 66.0,
 'step': 128766},
{'loss': 0.0019,
 'grad_norm': 0.00011001446546288207,
 'learning_rate': 6.600102511532548e-06,
 'epoch': 67.0,
 'step': 130717},
{'loss': 0.001,
 'grad_norm': 8.895299106370658e-05,
 'learning_rate': 6.400102511532548e-06,
 'epoch': 68.0,
 'step': 132668},
{'loss': 0.0032,
 'grad_norm': 7.830851973267272e-05,
 'learning_rate': 6.200102511532548e-06,
 'epoch': 69.0,
 'step': 134619},
{'loss': 0.001,
 'grad_norm': 8.124374289764091e-05,
 'learning_rate': 6.000102511532548e-06,
 'epoch': 70.0,
 'step': 136570},
{'loss': 0.0012,
 'grad_norm': 6.964178464841098e-05,
 'learning_rate': 5.800102511532548e-06,
 'epoch': 71.0,
 'step': 138521},
{'loss': 0.0004,
 'grad_norm': 0.00011098405957454816,
 'learning_rate': 5.600102511532548e-06,
 'epoch': 72.0,
 'step': 140472},
{'loss': 0.0012,
 'grad_norm': 6.558996392413974e-05,
 'learning_rate': 5.400102511532548e-06,
```

```
 'epoch': 73.0,
 'step': 142423},
{'loss': 0.002,
 'grad_norm': 6.981798651395366e-05,
 'learning_rate': 5.200102511532547e-06,
 'epoch': 74.0,
 'step': 144374},
{'loss': 0.0011,
 'grad_norm': 9.397657413501292e-05,
 'learning_rate': 5.0001025115325475e-06,
 'epoch': 75.0,
 'step': 146325},
{'loss': 0.0001,
 'grad_norm': 5.952797437203117e-05,
 'learning_rate': 4.800102511532548e-06,
 'epoch': 76.0,
 'step': 148276},
{'loss': 0.0009,
 'grad_norm': 6.855093670310453e-05,
 'learning_rate': 4.600102511532548e-06,
 'epoch': 77.0,
 'step': 150227},
{'loss': 0.0007,
 'grad_norm': 8.421037637162954e-05,
 'learning_rate': 4.400102511532548e-06,
 'epoch': 78.0,
 'step': 152178},
{'loss': 0.0007,
 'grad_norm': 0.000311187730403617,
 'learning_rate': 4.2001025115325475e-06,
 'epoch': 79.0,
 'step': 154129},
{'loss': 0.0005,
 'grad_norm': 5.1528390031307936e-05,
 'learning_rate': 4.000102511532548e-06,
 'epoch': 80.0,
 'step': 156080},
{'loss': 0.0011,
 'grad_norm': 0.00023477355716750026,
 'learning_rate': 3.800102511532548e-06,
 'epoch': 81.0,
 'step': 158031},
{'loss': 0.0001,
 'grad_norm': 4.747296770801768e-05,
 'learning_rate': 3.6001025115325478e-06,
 'epoch': 82.0,
 'step': 159982},
```

{'loss': 0.0001,
 'grad_norm': 7.038401236059144e-05,
 'learning_rate': 3.4001025115325476e-06,
 'epoch': 83.0,
 'step': 161933},
{'loss': 0.0001,
 'grad_norm': 6.0958769608987495e-05,
 'learning_rate': 3.200102511532548e-06,
 'epoch': 84.0,
 'step': 163884},
{'loss': 0.0006,
 'grad_norm': 5.622939715976827e-05,
 'learning_rate': 3.0001025115325476e-06,
 'epoch': 85.0,
 'step': 165835},
{'loss': 0.0005,
 'grad_norm': 5.253921335679479e-05,
 'learning_rate': 2.8001025115325474e-06,
 'epoch': 86.0,
 'step': 167786},
{'loss': 0.0006,
 'grad_norm': 4.477059337659739e-05,
 'learning_rate': 2.600102511532548e-06,
 'epoch': 87.0,
 'step': 169737},
{'loss': 0.0006,
 'grad_norm': 5.2265259000705555e-05,
 'learning_rate': 2.400102511532548e-06,
 'epoch': 88.0,
 'step': 171688},
{'loss': 0.0001,
 'grad_norm': 5.304967635311186e-05,
 'learning_rate': 2.2001025115325476e-06,
 'epoch': 89.0,
 'step': 173639},
{'loss': 0.0001,
 'grad_norm': 5.025915743317455e-05,
 'learning_rate': 2.0001025115325474e-06,
 'epoch': 90.0,
 'step': 175590},
{'loss': 0.0004,
 'grad_norm': 4.8748475819593295e-05,
 'learning_rate': 1.8001025115325476e-06,
 'epoch': 91.0,
 'step': 177541},
{'loss': 0.0001,
 'grad_norm': 5.530529597308487e-05,

```
 'learning_rate': 1.6001025115325474e-06,
 'epoch': 92.0,
 'step': 179492},
{'loss': 0.0001,
 'grad_norm': 5.2815354138147086e-05,
 'learning_rate': 1.4001025115325475e-06,
 'epoch': 93.0,
 'step': 181443},
{'loss': 0.0001,
 'grad_norm': 0.00035070712328888476,
 'learning_rate': 1.2001025115325475e-06,
 'epoch': 94.0,
 'step': 183394},
{'loss': 0.0003,
 'grad_norm': 5.347467231331393e-05,
 'learning_rate': 1.0001025115325475e-06,
 'epoch': 95.0,
 'step': 185345},
{'loss': 0.0001,
 'grad_norm': 4.8026995500549674e-05,
 'learning_rate': 8.001025115325475e-07,
 'epoch': 96.0,
 'step': 187296},
{'loss': 0.0001,
 'grad_norm': 5.2573781431419775e-05,
 'learning_rate': 6.001025115325475e-07,
 'epoch': 97.0,
 'step': 189247},
{'loss': 0.0001,
 'grad_norm': 4.97226465085987e-05,
 'learning_rate': 4.0010251153254745e-07,
 'epoch': 98.0,
 'step': 191198},
{'loss': 0.0001,
 'grad_norm': 3.9910522900754586e-05,
 'learning_rate': 2.0010251153254743e-07,
 'epoch': 99.0,
 'step': 193149},
{'loss': 0.0001,
 'grad_norm': 4.0194852772401646e-05,
 'learning_rate': 1.025115325474116e-10,
 'epoch': 100.0,
 'step': 195100},
{'train_runtime': 92581.542,
 'train_samples_per_second': 33.708,
 'train_steps_per_second': 2.107,
 'total_flos': 8.21090670461952e+17,
```

```
  'train_loss': 0.019456814793150954,
  'epoch': 100.0,
  'step': 195100}]
```

[57]:
```
###Salvar modelo para execucao
```

[58]:
```
import os

# Define the directory to save the model and tokenizer
output_dir = '/dados_abertos_stj/saved_models/model_with_stop_words'

# Create the output directory if it doesn't exist
os.makedirs(output_dir, exist_ok=True)

# Save the trained model
model.save_pretrained(output_dir)

# Save the tokenizer
tokenizer.save_pretrained(output_dir)

print(f"Model and tokenizer saved to {output_dir}")
```

```
Model and tokenizer saved to
/dados_abertos_stj/saved_models/model_with_stop_words
```

###Curva de convergência

[59]:
```
import matplotlib.pyplot as plt

# Get the training history
history = trainer.state.log_history

# Extract loss and learning rate values and steps
steps = []
loss_values = []
learning_rates = []

for entry in history:
    if 'loss' in entry:
        steps.append(entry['step'])
        loss_values.append(entry['loss'])
    if 'learning_rate' in entry:
        learning_rates.append(entry['learning_rate'])

# Ensure learning_rates list has the same length as steps/loss_values
# This might be necessary if learning_rate is not logged at every step
# A simple forward fill or interpolation could be used if needed,
# but for now, assume they are logged at similar intervals.
```

```
# If the lengths differ significantly, further investigation of the log history␣
 ↪structure is needed.
# For this example, we'll assume they align closely or learning_rate entries␣
 ↪are sufficient.
# A more robust approach would match steps between loss and learning_rate␣
 ↪entries.

# Simple check: if lengths differ, we might need a more sophisticated approach
if len(steps) != len(learning_rates):
    print("Warning: Length of loss and learning rate entries in history differ.
 ↪")
    # Depending on logging frequency, you might need to align these based on␣
 ↪'step'

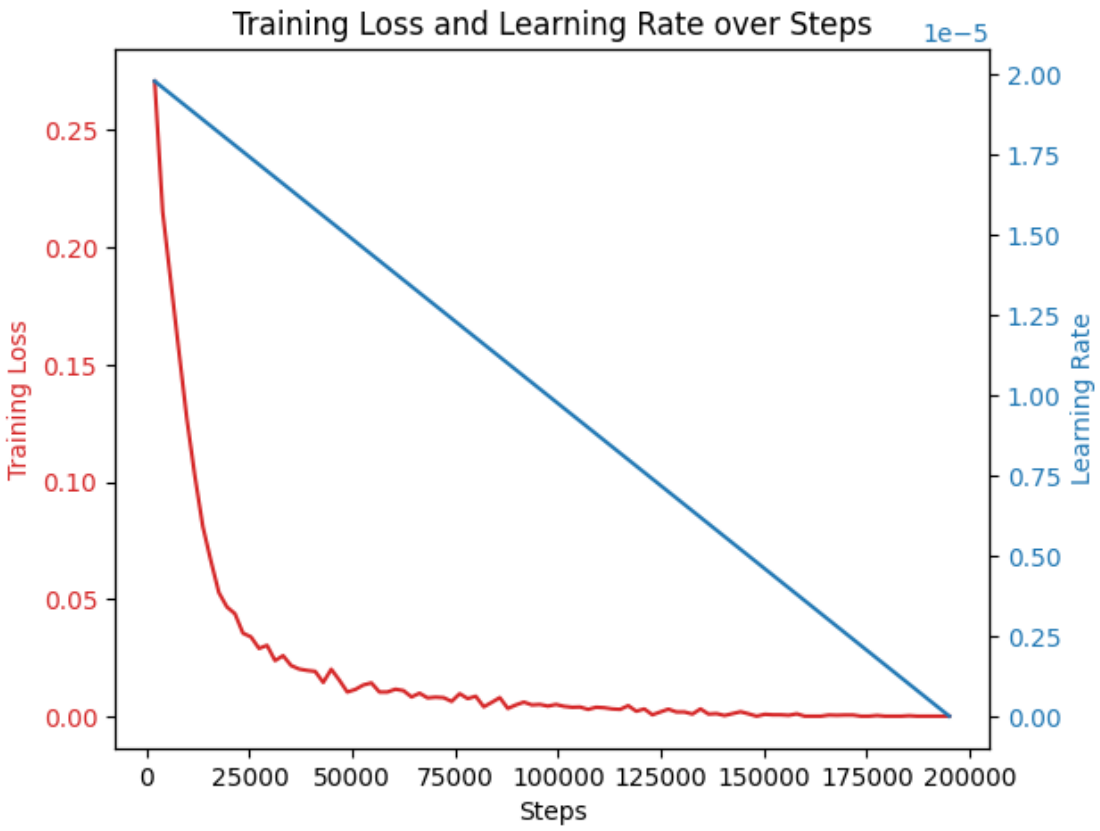
# Plot the convergence curve and learning rate
fig, ax1 = plt.subplots()

color = 'tab:red'
ax1.set_xlabel('Steps')
ax1.set_ylabel('Training Loss', color=color)
ax1.plot(steps, loss_values, color=color)
ax1.tick_params(axis='y', labelcolor=color)

ax2 = ax1.twinx()  # instantiate a second axes that shares the same x-axis

color = 'tab:blue'
ax2.set_ylabel('Learning Rate', color=color)  # we already handled the x-label␣
 ↪with ax1
ax2.plot(steps, learning_rates, color=color)
ax2.tick_params(axis='y', labelcolor=color)

fig.tight_layout()  # otherwise the right y-label is slightly clipped
plt.title('Training Loss and Learning Rate over Steps')
plt.show()
```



###Avaliação propriamenta dita

[60]:
```
trainer.evaluate()
```

```
<IPython.core.display.HTML object>
```

[60]:
```
{'eval_loss': 1.0972071886062622,
 'eval_f1': 0.6725855348635773,
 'eval_runtime': 171.756,
 'eval_samples_per_second': 97.836,
 'eval_steps_per_second': 6.119,
 'epoch': 100.0}
```

[ ]:
```

```

###Matriz de Confusão

[61]:
```
from sklearn.metrics import confusion_matrix, ConfusionMatrixDisplay
import matplotlib.pyplot as plt
import numpy as np

# Get predictions from the trainer
```

```
predictions = trainer.predict(tokenized_test)
```

[69]:
```
import matplotlib.pyplot as plt
import numpy as np
from sklearn.metrics import (
    confusion_matrix,
    ConfusionMatrixDisplay,
    accuracy_score,
    precision_score,
    recall_score,
    f1_score
)

# --- Seus dados (simulados para o exemplo funcionar) ---
# ... (predicted_labels e true_labels são gerados aqui) ...
# predicted_labels = np.argmax(predictions.predictions, axis=1)
# true_labels = tokenized_test["labels"]

# --- Novas Métricas ---
print("=" * 30)
print("MÉTRICAS DE AVALIAÇÃO")
print("=" * 30)

# Accuracy (Acurácia)
accuracy = accuracy_score(true_labels, predicted_labels)
print(f"Accuracy (Acurácia): {accuracy:.4f}")

# Precision (Precisão)
precision = precision_score(true_labels, predicted_labels)
print(f"Precision (Precisão): {precision:.4f}")

# Recall (Revocação / Sensibilidade / True Positive Rate - TPR)
recall = recall_score(true_labels, predicted_labels)
print(f"Recall (Sensibilidade/TPR): {recall:.4f}")

# True Negative Rate (TNR) / Specificity (Especificidade)
# Esta é a "revocação" da classe negativa (label = 0)
tnr = recall_score(true_labels, predicted_labels, pos_label=0)
print(f"True Negative Rate (Especificidade/TNR): {tnr:.4f}")

# --- ADICIONADO AQUI ---
# False Positive Rate (FPR)
# É o complemento da Especificidade (FPR = 1 - TNR)
fpr = 1 - tnr
print(f"False Positive Rate (FPR): {fpr:.4f}")
# --- FIM DA ADIÇÃO ---
```

```python
# F1-Score
f1 = f1_score(true_labels, predicted_labels)
print(f"F1-Score: {f1:.4f}")

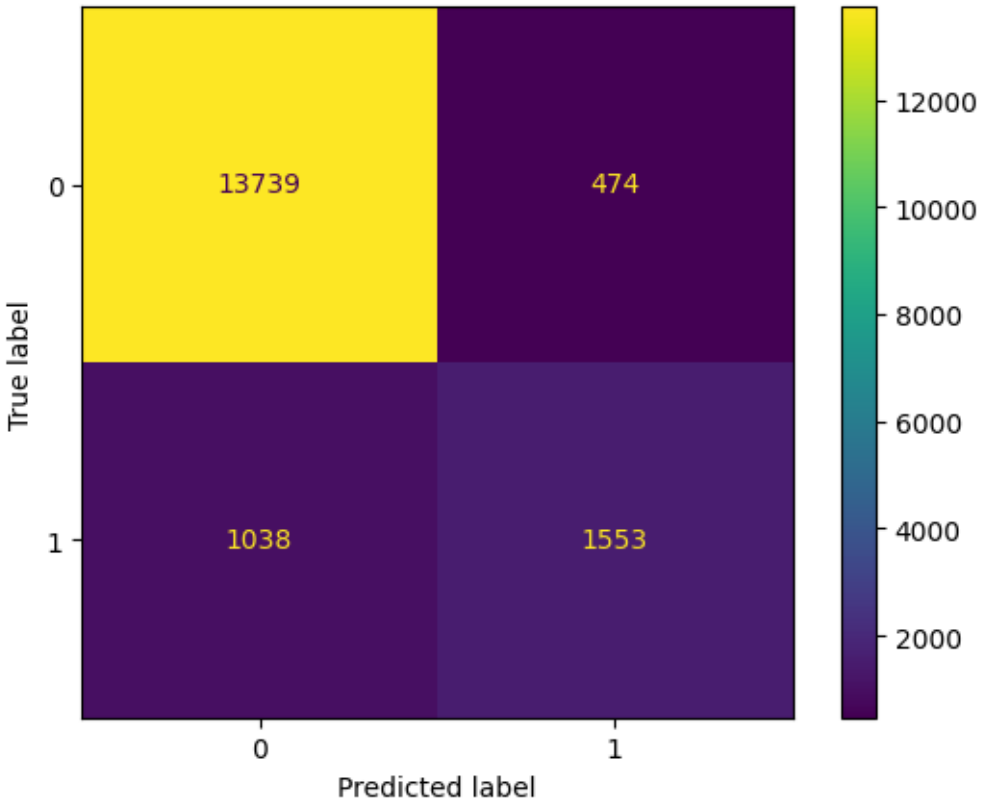
print("-" * 30)

# --- Plot da Matriz de Confusão ---

# Generate the confusion matrix
cm = confusion_matrix(true_labels, predicted_labels)

# Display the confusion matrix with desired label order
disp = ConfusionMatrixDisplay(confusion_matrix=cm)
disp.plot()
plt.show()
```

```
==============================
MÉTRICAS DE AVALIAÇÃO
==============================
Accuracy (Acurácia): 0.9100
Precision (Precisão): 0.7662
Recall (Sensibilidade/TPR): 0.5994
True Negative Rate (Especificidade/TNR): 0.9667
False Positive Rate (FPR): 0.0333
F1-Score: 0.6726
------------------------------
```



###Curva ROC

[63]:
```
import matplotlib.pyplot as plt
from sklearn.metrics import auc
from sklearn.metrics import roc_curve

# Get the prediction scores (probabilities) for the positive class
# For binary classification with logits, you typically apply a sigmoid or␣
 ↪softmax
# Here, assuming logits, we'll take the exponent of the positive class logit
# If your model outputs probabilities directly, adjust this line
prediction_scores = np.exp(predictions.predictions[:, 1]) / np.sum(np.
 ↪exp(predictions.predictions), axis=1)

# Get the true labels
true_labels = tokenized_test["labels"]

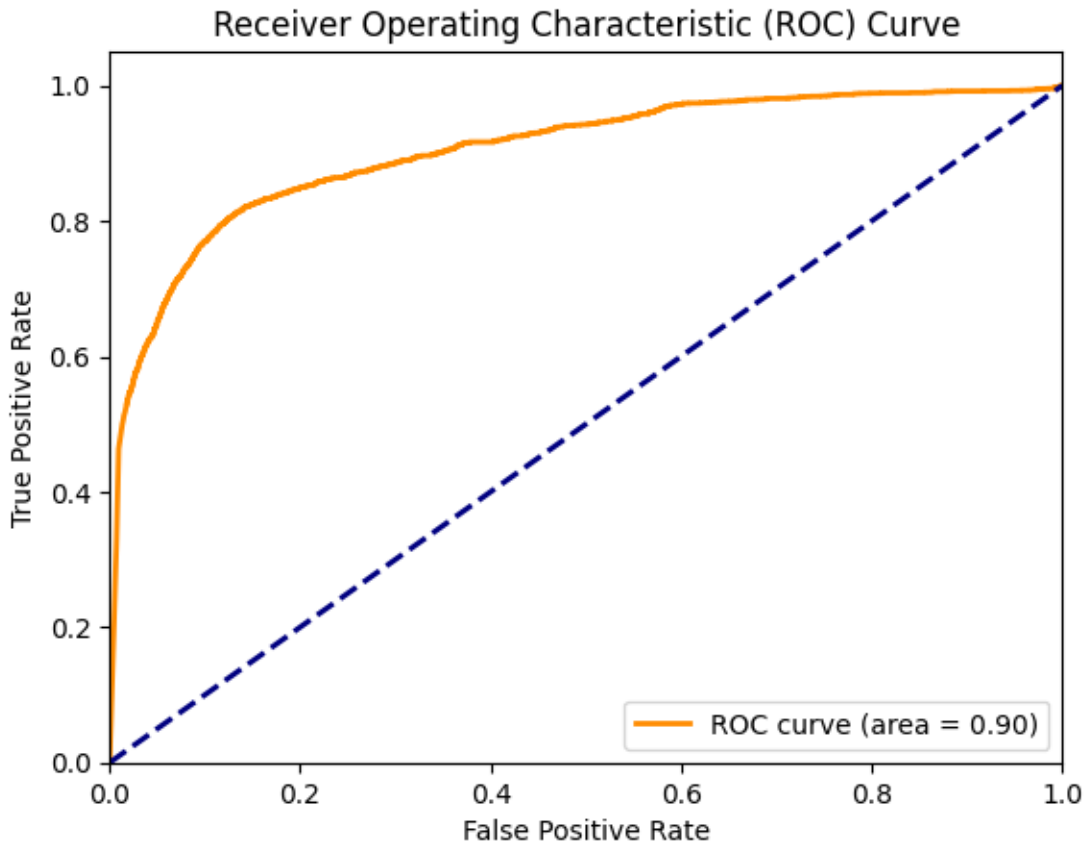
# Calculate the ROC curve points
fpr, tpr, thresholds = roc_curve(true_labels, prediction_scores)

# print("False Positive Rate (FPR):", fpr)
```

```
# print("True Positive Rate (TPR):", tpr)
# print("Thresholds:", thresholds)

# Calculate the Area Under the Curve (AUC)
roc_auc = auc(fpr, tpr)

# Plot the ROC curve
plt.figure()
plt.plot(fpr, tpr, color='darkorange', lw=2, label='ROC curve (area = %0.2f)' %␣
 ↪roc_auc)
plt.plot([0, 1], [0, 1], color='navy', lw=2, linestyle='--')
plt.xlim([0.0, 1.0])
plt.ylim([0.0, 1.05])
plt.xlabel('False Positive Rate')
plt.ylabel('True Positive Rate')
plt.title('Receiver Operating Characteristic (ROC) Curve')
plt.legend(loc="lower right")
plt.show()
```



[64]:
```
import pandas as pd
import matplotlib.pyplot as plt
import sys

def plot_training_history(log_history: list):
    """
    Processa o log_history do Hugging Face Trainer e plota os gráficos
    de perda (loss) e métricas de avaliação.

    Args:
        log_history (list): A lista de dicionários de trainer.state.log_history.
    """

    # 1. Separar logs de treino e avaliação
    train_logs = []
    eval_logs = []

    for log in log_history:
        if 'eval_loss' in log:
            # Este é um log de avaliação
            eval_logs.append(log)
        elif 'loss' in log:
            # Este é um log de treino (passo a passo)
            train_logs.append(log)
        # Ignoramos os logs de resumo final (ex: 'train_runtime')

    if not train_logs and not eval_logs:
        print("Histórico de log está vazio ou não contém logs de treino/
↪avaliação.", file=sys.stderr)
        return

    # 2. Criar DataFrames
    train_df = pd.DataFrame(train_logs)
    eval_df = pd.DataFrame(eval_logs)

    # 3. Determinar o eixo X (preferir 'epoch', mas usar 'step' se 'epoch' não␣
↪estiver)
    x_axis_train = 'epoch' if 'epoch' in train_df.columns else 'step'
    x_axis_eval = 'epoch' if 'epoch' in eval_df.columns else 'step'

    # 4. Encontrar a primeira métrica de avaliação (ex: 'eval_f1',␣
↪'eval_accuracy')
    metric_name = None
    if not eval_df.empty:
        for col in eval_df.columns:
            if col.startswith('eval_') and col not in ['eval_loss',␣
↪'eval_runtime',
```

```
                                                                    ␣
↪'eval_samples_per_second',
                                                                     'eval_steps_per_second']:
                metric_name = col
                break  # Encontramos a primeira métrica

    # 5. Criar os plots

    # Determinar quantos subplots precisamos
    num_plots = 1 + (1 if metric_name else 0)

    if num_plots == 2:
        fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(18, 6))
    else:
        fig, ax1 = plt.subplots(1, 1, figsize=(9, 6))
        ax2 = None # Sem segundo eixo

    # --- Gráfico 1: Perda (Loss) ---
    if not train_df.empty:
        ax1.plot(train_df[x_axis_train], train_df['loss'], label='Training␣
↪Loss', alpha=0.7)
    if not eval_df.empty:
        ax1.plot(eval_df[x_axis_eval], eval_df['eval_loss'], label='Validation␣
↪Loss',
                 marker='o', markersize=5, linestyle='--')

    ax1.set_title('Training vs. Validation Loss')
    ax1.set_xlabel('Epoch' if x_axis_train == 'epoch' else 'Step')
    ax1.set_ylabel('Loss')
    ax1.legend()
    ax1.grid(True, linestyle=':', alpha=0.6)

    # --- Gráfico 2: Métrica (se existir) ---
    if ax2 and metric_name:
        if not eval_df.empty:
            ax2.plot(eval_df[x_axis_eval], eval_df[metric_name],
                     label=f'Validation {metric_name}',
                     marker='o', markersize=5, linestyle='--', color='green')

        ax2.set_title(f'Validation Metric ({metric_name})')
        ax2.set_xlabel('Epoch' if x_axis_eval == 'epoch' else 'Step')
        ax2.set_ylabel(metric_name)
        ax2.legend()
        ax2.grid(True, linestyle=':', alpha=0.6)

    # Salvar e mostrar o gráfico
    plt.tight_layout()
```

```
    plot_filename = 'training_history.png'
    plt.savefig(plot_filename)

    print(f"  Gráficos de histórico de treino salvos em '{plot_filename}'")
```

[65]:
```
plot_training_history(trainer.state.log_history)
```

```
Gráficos de histórico de treino salvos em 'training_history.png'
```

